

《数据分析课程设计》

基于 ICR 数据的主要疾病的分类预测分析

摘要

项目来源:来自于 Kaggle 上正在进行的竞赛项目。

比赛主办方: 比赛主办方: 竞赛主办方 InVitro Cell Research, LLC (ICR)成立于 2015 年,是 一家专注于再生和预防性个性化医疗的私募公司。他们在大纽约地区的办公室和实验室提供最先进 的研究空间。

比赛目标: 预测一个人是否患有三种疾病中的任何一种; 患有一种或多种 (class 1), 没有这三种 疾病中的一种(class 0)。

比赛数据:包含与三种与年龄相关的状况相关联的五十多个匿名健康特征(脱敏)。目标是预测受 试者是否被诊断出患有这些病症之一,即是二元分类问题。

- train.csv---训练集。
 - ◆ ID 每个观察的唯一标识符。
 - ◆ AB-GL 五十六个匿名的健康特征。除了 EJ, 是类别型变量, 其余都是数值型。
 - ◆ Class 二元目标: 1表示已被诊断为三种情况之一, 0表示没有。
- test.csv ---测试集。目标是预测该集合中的受试者属于两个类别中的每个类别的概率。
- greeks.csv---补充元数据,仅适用于训练集。
 - Alpha: 标识与年龄相关的状况的类型(如果存在)。
 - A没有与年龄有关的情况。对应 class 0
 - B, D, G 三种与年龄有关的情况。对应 class 1
 - ◆ Beta, Gamma, Delta 三个实验特性
 - ◆ Epsilon 收集该主题数据的日期。请注意,测试集中的数据都是在收集训练集之后收集的。
- sample submission.csv ---格式正确的示例提交文件。




图 1-1 项目介绍

一、提出问题

- 1. 训练数据少的前提下,如何有效进行数据的各项处理处理?
- 2. 在数据集当中的所有特征变量都是脱敏的情况下,如何进行特征选择?
- 3. 目前, XGBoost 和随机森林等模型用于预测医疗状况, 但模型的性能还不够好, 如何进行调整优化?

二、获取数据

1. 导包

Loading Libraries

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib
from sklearn.model_selection import KFold, StratifiedKFold, train_test_split, GridSearchCV
from sklearn.metrics import roc_auc_score, accuracy_score, confusion_matrix, ConfusionMatrixDisplay, RocCurveDisplay
from sklearn.metrics import classification_report
from sklearn.metrics import confusion_matrix
from sklearn.metrics import roc curve,auc
from sklearn.metrics import precision_recall_curve
from sklearn.metrics import accuracy_score
plt.rcParams["font.sans-serif"]=['SimHei']
plt.rcParams["axes.unicode_minus"]=False
plt.rcParams.update({'font.size':13 }) #全局字体大小
plt.rcParams["font.family"]=['SimHei']
plt.rcParams['axes.unicode_minus']=False
```

图 2-1 导包

2. 读入数据集

load dataset

```
train = pd.read_csv('.//data/train.csv')
greeks = pd.read_csv('.//data/greeks.csv')
test = pd.read_csv('.//data/test.csv')
sample_submission = pd.read_csv('.//data/sample_submission.csv')
```

图 2-2 读入数据集

3. 查看数据基本情况

show dataset

```
print('train:',train.shape)
print('test:',test.shape)
print('greeks:',greeks.shape)

train: (617, 58)
test: (5, 57)
greeks: (617, 6)
图 2-3 数据基本情况
```

三、数据预处理和探索性分析

1. 训练集信息

```
train.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 617 entries, 0 to 616
Data columns (total 58 columns):
# Column Non-Null Count Dtype
                                      30 DI
                                                               float64
                                                 617 non-null
                                                 617 non-null
                                                               float64
                                     31 DL
          617 non-null object
                                     32 DN
                                                 617 non-null
                                                               float64
           617 non-null float64
                                      33 DU
                                                 617 non-null
                                                               float64
   ΔF
                       float64
2
           617 non-null
                       float64
                                      34 DV
                                                 617 non-null
                                                               float64
    ΔН
           617 non-null
3
    ΔΜ
           617 non-null
                        float64
                                      35 DY
                                                 617 non-null
                                                               float64
4
    AR
           617 non-null
                         float64
                                      36 EB
                                                 617 non-null
                                                               float64
                       float64
                                     37 EE
6
    AX
           617 non-null
                                                 617 non-null
                                                               float64
                       float64
           617 non-null
                                     38 EG
                                                 617 non-null
    ΔΥ
                                                               float64
7
   ΑZ
           617 non-null
                       float64
                                     39 EH
                                                617 non-null
                                                               float64
8
    ВС
           617 non-null
                       float64
                                     40 EJ
                                                617 non-null
                                                               object
10 BD
           617 non-null float64
                                     41 EL
                                                617 non-null float64
11 BN
           617 non-null
                       float64
                                     42 EP
                                                617 non-null float64
                       float64
    BP
           617 non-null
12
                                     43 EU
                                                617 non-null float64
                       float64
13
    BQ
           617 non-null
                                     44 FC
                                                617 non-null float64
    BR
           617 non-null
                        float64
14
                                     45 FD
                                                617 non-null float64
                       float64
                                     46 FE
15
    ΒZ
           617 non-null
                                                617 non-null
                                                               float64
                       float64
           617 non-null
                                     47 FI
                                                617 non-null
16 CB
                                                               float64
17 CC
           617 non-null
                       float64
                                      48 FL
                                                617 non-null
                                                               float64
18 CD
           617 non-null
                       float64
                                      49 FR
                                                 617 non-null
                                                               float64
19 CF
           617 non-null float64
                                     50 FS
                                                 617 non-null
                                                               float64
                       float64
           617 non-null
20 CH
                                     51 GB
                                                617 non-null
                                                               float64
                       float64
           617 non-null
21 CI
                                     52 GE
                                                617 non-null
                                                               float64
22
    CR
           617 non-null
                        float64
                                     53 GE
                                                617 non-null
                                                               float64
23
    CS
           617 non-null
                         float64
                                     54 GH
                                                617 non-null float64
                       float64
24 CU
           617 non-null
                                     55 GI
                                                617 non-null float64
           617 non-null
                       float64
25 CW
                                     56 GL
                                                617 non-null float64
           617 non-null
                       float64
26 DA
                                     57 Class 617 non-null
27 DE
           617 non-null
                       float64
                                    dtypes: float64(55), int64(1), object(2)
28 DF
           617 non-null
                       float64
                                     memory usage: 284.4+ KB
29 DH
           617 non-null
                         float64
```

图 3-1 训练集信息

2. 查看训练集的缺失情况

```
# Missing training data
Missing col = train.isnull().sum()[train.isnull().sum().values!=0]
Missing_col
BQ
      60
CB
       2
CC
       3
DU
       1
EL
      60
FC
       1
FL
       1
FS
       2
       1
GL
dtype: int64
```

分析:由于训练集数据量有限,故而不能简单采取删除缺失列的方法。

3. 处理缺失值

处理思路:

- 合并 train 和 greeks (训练集的补充元数据)
- 查看变量列中缺少值的 Alpha 情况
- 根据步骤 1 中获得的"Alpha"计算变量列的平均值
- 替换与此列相关的缺失值
- 1) 拼接 train 和 greeks 两个数据集

```
# 拼接train和greeks两个数据集
train = pd.merge(train,greeks,on='Id')
train.sample(5)
          ld
                  AB
                                      AH
                                                AM
                                                          AR
                                                                   AX
                                                                            AY
                                                                                     ΑZ
                                                                                                                     GH
 c214d487e2db 0.235015 2648.34515 85.200147 10.474054 8.138688 2.919040 0.033495 3.396778 2.371950 ... 16045.77406 19.665485 20.851204 0.260780
14a3f3cc04bd 0.559763 3263.59506 85.200147 85.083811 8.138688 13.208769 0.025578 11.980102 1.229900 ... 13150.30853 19.092451 69.901816 21.978000
 a46b439e1eac 0.615312 5379.22198 117.667299 30.477577 8.138688 5.590029 0.025578 11.129332 1.229900 ... 20268.14279 27.286093 48.770264 0.173909
c5e5456ccaa2 0.247834 2925.54768 85.200147 25.565735 8.138688 4.704129 0.025578 3.396778 1.229900 ... 28431.62111 26.839573 26.805384 0.133562 0
 8b9d72eec14e 4.277273 7314.15234 85.200147 630.518230 59.390922 6.936597 0.025578 18.805168 4.649022 ... 14702.79859 39.427716 74.479976 0.013500 0
ws × 63 columns
```

图 3-3 拼接 train 和 greeks

2) 缺失值处理

'BQ'

```
# 查看变量列'BO'缺失值的 Alpha 情况
train[['BQ','Alpha']][train.BQ.isnull()]['Alpha'].unique()
array(['A'], dtype=object)
```

分析: 缺失值的'Alpha'都为'A';表示:没有与年龄相关的疾病。对应目标变量: 类别 0

```
# 采用'Alpha'=='A'的'BQ'均值替换此列缺失值
mean = train[train.Alpha=='A']['BQ'].mean()
train.BQ.fillna(mean,inplace=True)
```

'CB'

```
# 查看变量列'CB'缺失值的 Alpha 情况
train[['CB','Alpha']][train.CB.isnull()]['Alpha'].unique()
```

array(['A'], dtype=object)

分析: 缺失值的'Alpha'都为'A';表示:没有与年龄相关的疾病。对应目标变量: 类别 0

```
# 采用'Alpha'=='A'的'CB'均值替换此列缺失值
mean = train[train.Alpha=='A']['CB'].mean()
train.CB.fillna(mean,inplace=True)
```

```
'CC'
# 查看变量列'CC'缺失值的 Alpha 情况
train[['CC','Alpha']][train.CC.isnull()]['Alpha'].unique()
array(['A', 'D'], dtype=object)
分析: 缺失值的'Alpha'为'A'和'D';表示:既有没有与年龄相关的疾病; 也有与年龄相关的疾病。对应目标变量; 类别 0 和类别 1
# 采用'ALpha'=='A'/'D'的'CC'均值替换此列缺失值
mean1 = train[train.Alpha=='A']['CC'].mean()
mean2 = train[train.Alpha=='D']['CC'].mean()
for i in train[(train.Alpha=='A') & (train.CC.isnull())].index:
   temp = train[train.index==i].copy()
   temp.CC=mean1
   train[train.index==i] = temp
for i in train[(train.Alpha=='D') & (train.CC.isnull())].index:
   temp = train[train.index==i].copy()
   temp.CC=mean2
   train[train.index==i] = temp
'DU'
# 查看变量列'DU'缺失值的 Alpha 情况
train[['DU','Alpha']][train.DU.isnull()]['Alpha'].unique()
array(['A'], dtype=object)
分析: 缺失值的'Alpha'都为'A';表示:没有与年龄相关的疾病。对应目标变量: 类别 0
# 采用'Alpha'=='A'的'DU'均值替换此列缺失值
mean = train[train.Alpha=='A']['DU'].mean()
train.DU.fillna(mean,inplace=True)
  'EL'
  # 查看变量列'DU'缺失值的 Alpha 情况
  train[['EL','Alpha']][train.EL.isnull()]['Alpha'].unique()
  array(['A', 'B', 'G', 'D'], dtype=object)
  分析: 缺失值的'Alpha'为'A'和'D':表示:既有没有与年龄相关的疾病; 也有与年龄相关的疾病。对应目标变量: 类别 0 和类别 1
  # 采用'Alpha'=='A'/'D'的'CC'均值替换此列缺失值
  mean1 = train[train.Alpha=='A']['EL'].mean()
  mean2 = train[train.Alpha=='B']['EL'].mean()
  mean3 = train[train.Alpha=='D']['EL'].mean()
  mean4 = train[train.Alpha=='G']['EL'].mean()
  for i in train[(train.Alpha=='A') & (train.EL.isnull())].index:
     temp = train[train.index==i].copy()
      temp.EL = mean1
      train[train.index==i] = temp
  for i in train[(train.Alpha=='B') & (train.EL.isnull())].index:
      temp = train[train.index==i].copy()
      temp.EL = mean2
      train[train.index==i] = temp
  for i in train[(train.Alpha=='D') & (train.EL.isnull())].index:
     temp = train[train.index==i].copy()
      temp.EL = mean3
      train[train.index==i] = temp
   for i in train[(train.Alpha=='G') & (train.EL.isnull())].index:
     temp = train[train.index==i].copy()
      temp.EL = mean4
      train[train.index==i] = temp
```

```
'FC'
    # 查看变量列'FC'缺失值的 Alpha 情况
     train[['FC', 'Alpha']][train.FC.isnull()]['Alpha'].unique()
    array(['D'], dtype=object)
     分析: 缺失值的'Alpha'为'A'和'D';表示:有与年龄相关的疾病。对应目标变量: 类别 1
    # 采用'Alpha'=='D'的'FC'均值替换此列缺失值
     mean = train[train.Alpha=='D']['FC'].mean()
     train.FC.fillna(mean,inplace=True)
    'FL'
    # 查看变量列'FC'缺失值的 Alpha 情况
     train[['FL','Alpha']][train.FL.isnull()]['Alpha'].unique()
  : array(['A'], dtype=object)
     分析: 缺失值的'Alpha'都为'A';表示:没有与年龄相关的疾病。对应目标变量: 类别 0
    # 采用'Alpha'=='A'的'DU'均值替换此列缺失值
     mean = train[train.Alpha=='A']['FL'].mean()
     train.FL.fillna(mean,inplace=True)
 'FS'
 # 查看变量列'FC'缺失值的 Alpha 情况
 train[['FS','Alpha']][train.FS.isnull()]['Alpha'].unique()
array(['D', 'A'], dtype=object)
 分析: 缺失值的'Alpha'为'A'和'D';表示:既有没有与年龄相关的疾病; 也有与年龄相关的疾病。对应目标变量: 类别 0 和类别 1
# 采用'Alpha'=='A'/'D'的'CC'均值替换此列缺失值
 mean1 = train[train.Alpha=='A']['FS'].mean()
 mean2 = train[train.Alpha=='D']['FS'].mean()
 for i in train[(train.Alpha=='A') & (train.F5.isnull())].index:
    temp = train[train.index==i].copy()
    temp.FS=mean1
    train[train.index==i] = temp
  for i in train[(train.Alpha=='D') & (train.FS.isnull())].index:
    temp = train[train.index==i].copy()
    temp.FS=mean2
    train[train.index==i] = temp
 'GL'
 # 查看变量列'GL'缺失值的 Alpha 情况
 train[['GL','Alpha']][train.GL.isnull()]['Alpha'].unique()
: array(['A'], dtype=object)
 分析: 缺失值的'Alpha'都为'A';表示:没有与年龄相关的疾病。对应目标变量: 类别 0
: # 采用'Alpha'=='A'的'GL'均值替换此列缺失值
 mean = train[train.Alpha=='A']['GL'].mean()
 train.GL.fillna(mean,inplace=True)
```

3) 再次检查缺失值处理

```
# Recheck missing value handling(再次检查缺失值处理)
train.isnull().sum()[train.isnull().sum().values!=0]
```

Series([], dtype: int64)

图 3-5 再次查看缺失值处理情况

4) 移除 greeks 数据集相关列

```
# 去除缺失值后,移除greeks数据集相关列
train = train.iloc[:,0:58]
train.sample(5)
```

	ld	AB	AF	AH	AM	AR	AX	AY	AZ	ВС	
505	cc9f47d89979	0.769140	2199.85260	213.675315	30.973097	8.138688	4.580103	0.025578	3.396778	1.229900	
4	044fb8a146ec	0.380297	3733.04844	85.200147	14.103738	8.138688	3.942255	0.054810	3.396778	102.151980	
130	3493c79c8f35	0.202967	3301.82017	88.618430	13.473498	8.138688	3.946684	0.103225	10.789024	7.983808	
226	5a87a6061488	0.730683	1704.55725	152.921331	94.944729	8.138688	5.031912	0.036845	10.952876	1.229900	
292	7416fea10b6b	1.196440	4231.60958	85.200147	54.110784	8.138688	5.439426	0.025578	3.396778	7.150990	


5 rows × 58 columns


图 3-6 移除 greeks 数据集

4. 探索性分析 (EDA)

1)目标变量'Class'分布情况

distribution of 'Class':





分析: 训练集当中目标变量的分布情况并不均衡, 因此在后续应当考虑变量平衡!

图 3-7 目标变量的分布情况

2) 数值型特征的分布

取出数值型特征变量名到 numerical 变量中

	AB	AF	AH	AM	AR	AX	AY	AZ	ВС	BD	
0	0.209377	3109.03329	85.200147	22.394407	8.138688	0.699861	0.025578	9.812214	5.555634	4126.58731	
1	0.145282	978.76416	85.200147	36.968889	8.138688	3.632190	0.025578	13.517790	1.229900	5496.92824	
2	0.470030	2635.10654	85.200147	32.360553	8.138688	6.732840	0.025578	12.824570	1.229900	5135.78024	
3	0.252107	3819.65177	120.201618	77.112203	8.138688	3.685344	0.025578	11.053708	1.229900	4169.67738	
4	0.380297	3733.04844	85.200147	14.103738	8.138688	3.942255	0.054810	3.396778	102.151980	5728.73412	


图 3-8 数值型特征变量


数值型特征变量分布情况(For 循环画图查看)


分析:由于此次的主题是疾病预测,同时数据集的各个特征变量都是脱敏的情况,因此对于数据集当中所谓的'异常值',并没有采取处理,因为它可能是预测受试者是否患病的重要一环。故而并没有采取绘制箱线图查看数据分布情况。

distribution(变量分布情况)

```
#数值型变量
plt.figure(figsize=(20,70))
i=1
for temp in numerical:
    plt.subplot(14,4,i)
    sns.histplot(data=train,x=temp,hue='Class',kde=True)
    i+=1
plt.show()
```







分析:从上述各图可看出,各个特征存在量纲差异,而且并不是所有特征都近似服从正态分布;从整体上看,目标变量的两种对应类别的特征变量分布大体呈现一致趋势。

类别型变量'EJ'的分布情况

```
# 类别型变量分布情况
plt.figure(figsize=(8,5))
sns.countplot(data=train,x='EJ',hue='Class')
plt.title("The distribution of 'EJ'")
plt.show()
```




图 3-10 类别型变量 EJ 的分布情况

四、建模和模型评价(可视化)

- 1. 特征工程
- 1) 备份数据集

```
# 备份数据集
train_ = train.copy()
test_ = test.copy()
```

图 4-1 备份

2) 独热编码转换

```
# 对 train_和 test_ 的 'EJ' 进行独热编码转换
train_ = pd.get_dummies(train_,columns=['EJ'],prefix_sep='_')
test_ = pd.get_dummies(test_,columns=['EJ'],prefix_sep='_')
```

图 4-2 独热编码转换

3)划分数据集

```
# 将训练集的目标变量和特征变量进行划分
X_train_ = train_.drop(['Class','Id'],axis=1)
Y = train_['Class']
```

```
from sklearn.model_selection import train_test_split
X_train, X_test,Y_train, Y_test = train_test_split(X_train_,Y,train_size=0.70, random_state=10)
图 4-3 划分数据集
```



2. 建模

1) 随机森林分类

```
# RandomForest
from sklearn.ensemble import RandomForestClassifier
RF = RandomForestClassifier()
RF.fit(X_train,Y_train)
print(f'Accuracy on train set: {RF.score(X_train, Y_train)*100}%')
print(f'Accuracy on test set: {RF.score(X_test, Y_test)*100}%')
# The evaluation of RandomForest
print(f"model evaluation report:\n{classification_report(Y_test,RF.predict(X_test))}")
Accuracy on train set: 100.0%
Accuracy on test set: 92.47311827956989%
model evaluation report:
             precision
                        recall f1-score support

    0.95
    0.96
    0.96

    0.78
    0.72
    0.75

                 0.95
                                              157
          0
                                                 29
          1
                                     0.92
                                                 186
   accuracy
                0.86 0.84 0.85
                                                 186
  macro avg
weighted avg
                0.92
                           0.92
                                    0.92
                                                 186
                            图 4-4 随机森林分类初始建模
```

2) XGBoost 分类

```
# xgboost
from xgboost import XGBClassifier
XGB = XGBClassifier()
XGB.fit(X_train,Y_train)
print(f'Accuracy on train set: {XGB.score(X_train, Y_train)*100}%')
print(f'Accuracy on test set: {XGB.score(X_test, Y_test)*100}%')
# The evaluation of XGBClassifier
print(f"model evaluation report:\n{classification_report(Y_test,XGB.predict(X_test))}")
Accuracy on train set: 100.0%
Accuracy on test set: 93.01075268817203%
model evaluation report:
            precision recall f1-score support
               0.96 0.96 0.96
                                             157
          0
                 0.77
                         0.79
                                    0.78
                                                29
   accuracy
                                    0.93
                                               186
                 0.86 0.87
   macro avg
                                    0.87
                                               186
                 0.93
weighted avg
                           0.93
                                    0.93
                                               186
```

图 4-5 XGBoost 分类初始建模

分析:结合此次竞赛主题是疾病预测领域,通常情况下更多关注的是召回率,即是查全率;因为高召回率意味着能将更多患病的预测出来,从上述两种建模算法的模型评价来看,XGBoost的召回率和准确率相较于随机森林分类都更胜一筹。

综上,选取 XGBoostClassifer 进行模型优化。

3) SelectFromModel 变量筛选

```
a. XGBClassifier 作为基模型的特征选择,先进行探索阈值
 from numpy import sort
 from sklearn.metrics import recall_score
 # 初始建模
 XGB = XGBClassifier()
 XGB.fit(X_train,Y_train)
 Y_pred = XGB.predict(X_test.values)
 recall = recall_score(Y_test, Y_pred)
 print("Recall_score: %.2f%%" % (recall * 100.0))
 # Fit model using each importance as a threshold
 thresholds = sort(XGB.feature importances )
 thresh_lt=[]
 n_lt = []
 recall_lt=[]
 for thresh in thresholds:
     # select features using threshold
     selection = SelectFromModel(XGB, threshold=thresh, prefit=True)
     select_X_train = selection.transform(X_train.values)
     # train model
     selection_model = XGBClassifier()
     selection_model.fit(select_X_train, Y_train)
     # eval model
     select_X_test = selection.transform(X_test.values)
     y_pred = selection_model.predict(select_X_test)
     predictions = [round(value) for value in y_pred]
     recall = recall_score(Y_test, predictions)
     thresh_lt.append(thresh)
     n lt.append(select_X_train.shape[1])
     recall_lt.append(recall*100.0)
 df_temp = pd.DataFrame({'threshold':thresholds,'n':n_lt,'recall(%)':recall_lt})
 df_temp
 Recall score: 84.95%
     threshold n recall(%)
                              0.007065 41 82.758621
                          16
                                                        0.014570 25 79.310345
     0.000000 57 79.310345
                              0.007168 40 82.758621
                                                        0.015998 24 75.862069
     0.000000 57 79.310345
                              0.007290 39 82.758621
                          18
                                                         0.016551 23 79.310345
     0.000000 57 79.310345
                          19
                              0.007820 38 82.758621
     0.000000 57 79.310345
                                                        0.017737 22 82.758621
                                                    35
                          20
                              0.009618 37 86.206897
                                                                                 46
                                                                                     0.029045 11 72.413793
     0.000559 53 79.310345
                                                    36
                                                         0.018214 21 82.758621
                              0.009764 36 75.862069
                          21
                                                                                 47
                                                                                     0.029416 10 75.862069
     0.000961 52 79.310345
                                                         0.018373 20 75.862069
                              0.010355 35 75.862069
                                                                                 48
                                                                                     0.030007
                                                                                               9 75.862069
     0.002898 51 79.310345
                                                         0.018743 19 82.758621
                                                    38
                              0.010606 34 82.758621
     0.002978 50 79.310345
  7
                                                                                 49
                                                                                     0.038757 8 79.310345
                              0.010908 33 72.413793
                          24
                                                         0.019161 18 79.310345
     0.003224 49 82.758621
                                                                                     0.039064
                                                                                               7 75.862069
                              0.011092 32 82.758621
                          25
     0.003710 48 79.310345
                                                         0.020217 17 68.965517
                                                                                     0.046040
                                                                                               6 68.965517
                          26
                              0.011465 31 82.758621
 10
     0.003846 47 75.862069
                                                         0.020322 16 72.413793
                                                                                     0.050107
                                                                                               5 72.413793
                          27
                              0.011724 30 72.413793
     0.004294 46 79.310345
                                                         0.021240 15 72.413793
                                                                                     0.052874
                                                                                               4 75.862069
                              0.011822 29 79.310345
     0.004872 45 79.310345
 12
                                                    43
                                                         0.022211 14 62.068966
                                                                                     0.056684
                                                                                               3 55,172414
                              0.012477 28 79.310345
 13
     0.005608 44 82.758621
                         29
                                                         0.024034 13 62.068966
                                                                                     0.057746
                                                                                               2 31.034483
                              0.012943 27 79.310345
     0.006593 43 82.758621
                          30
 14
                                                    45
                                                        0.026504 12 72.413793
                                                                                 56
                                                                                     0.084749
                                                                                             1 27.586207
     0.006868 42 86.206897 31 0.013110 26 79.310345
 15
                              图 4-6 XGBClassifier 作为基模型的特征选择探索
分析:从上可得,当阈值取到中位数时,recall分数趋于稳定。
```

15



```
from sklearn.feature_selection import SelectFromModel
 # XGBClassifier作为基模型的特征选择
 selector_XGBC = SelectFromModel(XGBClassifier(),threshold='median').fit(X_train,Y_train)
b. 执行筛选并展示
 print('SelectFromModel筛选前的特征变量维度:',X_train.shape)
 print('SelectFromModel筛选后的特征变量维度: ',selector XGBC.transform(X train).shape)
 SelectFromModel筛选前的特征变量维度: (431, 57)
 SelectFromModel筛选后的特征变量维度: (431, 29)
 selector_X = X_train.columns[selector_XGBC.get_support()].to_list()
 print('筛选后的特征变量个数:',len(selector_X))
 筛选后的特征变量个数: 29
c. 按照筛选成功的变量进行划分训练集和测试集
# 按照筛选的结果对train_进行划分训练集和测试集
X = train_.loc[:,selector_X]
Y = train_['Class']
from sklearn.model selection import train test split
X_train, X_test,Y_train, Y_test = train_test_split(X,Y,train_size=0.70, random_state=10)
                    图 4-7 XGBClassifier 作为基模型嵌入法的特征选择
d. 筛选后的变量的相关性分析(重要变量相关性热力图)
     train corr data = train .loc[:,selector X].corr(method='pearson')
     plt.figure(figsize=(10,6))
     sns.heatmap(train_corr_data,cmap=plt.cm.Blues)
     plt.show()
                                                                    0.8
     8
     줆
     쯂
                                                                    0.6
     ਡ
     띰
                                                                   -0.4
     ≥
                                                                   -0.2
     æ
     留
     B
                                                                   -0.0
     ᇁ
                                                                   --0.2
        图 4-8 重要变量相关性热力图
```

五、模型优化

XGBoostClassifer 参数调优,采取 GridSearchCV 进行调参,对 XGBoost 的重要参数进行选择优化,如 n_estimators(树的个数), max_depth(树的深度),learning_rate(学习率),min_child_weight(叶子节点中样本的权值,避免欠拟合)等;

由于训练集数据量有限,故而只采取5折交叉验证,避免模型出现过拟合。

```
from sklearn.model selection import GridSearchCV,StratifiedKFold
 from xgboost import XGBClassifier
 from sklearn.model_selection import KFold,StratifiedKFold
 XGB model = XGBClassifier()
 #params
 parameters = {'learning_rate':[0.01,0.1,0.3],'subsample':[0.3,0.5],
             'max_depth':[3,6,9],'n_estimators':[300,800,1500],
              'min_child_weight':[2,4,6],'max_delta_step':[3,5,7],
              'eta':[0.1,0.3]
 #5fold
 kfold = KFold(n_splits=5, shuffle=True, random_state=10)
 #GridSearchCV
 grid_search = GridSearchCV(XGB_model, parameters, scoring="recall",n_jobs=-1,cv=kfold)
 grid_result = grid_search.fit(X_train,Y_train)
 #best results
 print(f"Best:{grid result.best score };\nusing:\n{grid result.best params }")
调优结果:
Best:0.7238789280894544;
```

Best:0.7238789280894544;
using:
{'eta': 0.1, 'learning_rate': 0.01, 'max_delta_step': 3, 'max_depth': 6, 'min_child_weight': 2, 'n_estimators': 1500, 'subsample': 0.5}
图 4-9 模型调优

1)在网格调优的最优参数下探索模型复杂度与训练误差,测试误差以及交叉验证误差之间的情况 同时探索竞赛评价指标对数损失的情况。 计算对数损失函数:

$$\text{Log Loss} = \frac{-\frac{1}{N_0} \sum_{i=1}^{N_0} y_{0i} \text{log} p_{0i} - \frac{1}{N_1} \sum_{i=1}^{N_1} y_{1i} \text{log} p_{1i}}{2}$$

```
# 对数损失函数

def competition_log_loss(y_true, y_pred):
    # y_true: 真实值 标签 0, 1
    # y_pred: 预测患病 (class=1) 的概率
    # 使用实现评估方程式 w_0 = w_1 = 1.
    # 计算每个类别的观测次数
    N_0 = np.sum(1 - y_true)
    N_1 = np.sum(y_true)
    # 计算每个类别的预测概率
    p_1 = np.clip(y_pred, 1e-15, 1 - 1e-15)
    p_0 = 1 - p_1
    # 计算每类的平均对数损失
    log_loss_0 = -np.sum((1 - y_true) * np.log(p_0)) / N_0
    log_loss_1 = -np.sum(y_true * np.log(p_1)) / N_1
    # 返回
    return (log_loss_0 + log_loss_1)/2
```

循环探索不同模型复杂度下的各个误差并且进行可视化:

```
from xgboost import XGBClassifier
from sklearn.model_selection import cross_val_score
trainErr = [] #训练误差
testErr = [] #测试误差
CV_recall_Err = []
                     #交叉验证召回率误差
                     #交叉验证f1误差
CV_f1_Err = []
CV_precision_Err = []#交叉验证精确率误差
log_loss_lt = []
for k in np.arange(100,2000,100): #模型复杂度 K
    # model
   XGBC_model = XGBClassifier(n_estimators=k,max_depth=6,learning_rate=0.01,
                           subsample=0.5,eta=0.1,max delta step=3,min child weight=2,
                           random state=10)
   XGBC model.fit(X train, Y train)
   y pred = XGBC model.predict(X test)
    test_prob = XGBC_model.predict_proba(X_test)
   test_prob_df = pd.DataFrame(test_prob, columns=['class_0', 'class_1'])
    log_loss = competition_log_loss(Y_test,test_prob_df.class_1.to_list())
    log_loss_lt.append(log_loss)
    trainErr.append(1-XGBC_model.score(X_train,Y_train))
    testErr.append(1-(XGBC_model.score(X_test,Y_test)))
    recall_Err = 1-cross_val_score(XGBC_model,X,Y,cv=5,scoring='recall')
    f1_Err = 1-cross_val_score(XGBC_model,X,Y,cv=5,scoring='f1')
    precision_Err = 1-cross_val_score(XGBC_model,X,Y,cv=5,scoring='precision')
   CV_recall_Err.append(recall_Err.mean())
   CV_f1_Err.append(f1_Err.mean())
    CV precision Err.append(precision Err.mean())
```

图 4-11 for 循环计算不同模型复杂度下的误差

```
K = np.arange(100,2000,100)
plt.figure(figsize=(8,5))
plt.plot(K,log_loss_lt,label='log_loss',marker='o',linestyle = '-')
bestK = K[log_loss_lt.index(np.min(log_loss_lt))]
plt.xlabel('模型复杂程度')
plt.ylabel('对数损失')
plt.legend()
plt.title(f'模型复杂度和对数损失\n(Best K={bestK})',fontsize=18)
plt.show()
```




图 4-12 XGBoost 模型的对数损失折线图

绘制折线图显示模型复杂度与各误差之间的情况

```
K = np.arange(100,2000,100)
plt.figure(figsize=(20,6))
ax1 = plt.subplot(1,2,1)
ax1.grid(True,linestyle = '-.')
ax1.plot(K,trainErr,label='训练误差',marker='o',linestyle = '-')
ax1.plot(K,testErr,label='测试误差',marker='o',linestyle = '-.')
bestK = K[testErr.index(np.min(testErr))]
ax1.set xlabel('模型复杂程度')
ax1.set_ylabel('误差')
ax1.legend()
ax1.set title(f'模型复杂度和误差\n(Best K={bestK})',fontsize=18)
ax2 = plt.subplot(1,2,2)
ax2.grid(True,linestyle = '-.')
ax2.plot(K,CV_recall_Err,label='5折交叉验证_recall',marker='o',linestyle = '-')
ax2.plot(K,CV_f1_Err,label='5折交叉验证_f1',marker='o',linestyle = '-.')
ax2.plot(K,CV_precision_Err,label='5折交叉验证_precision',marker='o',linestyle = '--')
ax2.set xlabel('模型复杂程度')
ax2.set ylabel('误差')
ax2.legend()
ax2.set title(f'模型复杂度和误差\n交叉验证',fontsize=18)
plt.show()
```

模型复杂度和误差




图 4-13 XGBoost 模型的训练与测试误差折线图




图 4-14 XGBoost 模型的交叉验证误差折线图

分析: 从上图得出,当模型复杂度为 900 左右时,模型测试误差已经趋于平稳且变化较小,而且此时的训练误差已经趋于平稳,而此时评估指标对数损失也是较小而且趋于平稳。

2) XGBoost 模型建立

图 4-15 XGBoost 模型的建立

采用如上方法对于随机森林模型进行同样的探索

```
K = np.arange(100,2000,100)
plt.figure(figsize=(8,5))
plt.plot(K,log_loss_lt,label='log_loss',marker='o',linestyle = '-')
bestK = K[log_loss_lt.index(np.min(log_loss_lt))]
plt.xlabel('模型复杂程度')
plt.ylabel('对数损失')
plt.legend()
plt.title(f'随机森林模型复杂度和对数损失\n(Best K={bestK})',fontsize=18)
plt.show()
```




图 4-16 随机森林模型的探索结果可视化

结果分析:随机森林模型的模型探索情况表示,评估指标相较于 XGBoost 较大,而且随着模型复杂 度的增加,对数损失呈现先上升,平稳,稍微下降的趋势,结合初步探索以及此次的调优模型探索, 选定模型为 XGBoost

3. 模型评价

1)报告

```
# 模型的评价
print(f"model evaluation report:\n{classification_report(Y_test,XGBC_model.predict(X_test))}")
model evaluation report:
           precision recall f1-score support
                0.97
                                0.96
                       0.95
                                         157
         1
                0.75
                       0.83
                                0.79
                                           29
                                 0.93
                                         186
   accuracy
macro avg 0.86 0.89
weighted avg 0.93 0.93
                                 0.87
                                         186
                                0.93
                                           186
```

图 4-16 XGBoost 模型评价报告

2) 混淆矩阵

```
# 混淆矩阵

cnf_matrix = confusion_matrix(Y_test,XGBC_model.predict(X_test))

print(f'confusion matrix: \n{cnf_matrix}\n')

plt.figure(figsize=(8,4))

sns.heatmap(cnf_matrix,annot=True,cmap=plt.cm.Blues,fmt='g')

plt.title('the heatmap of confusion matrix')

plt.show()
```

confusion matrix:

```
[[149 8]
[ 5 24]]
```

the heatmap of confusion matrix




图 4-17 XGBoost 模型混淆矩阵

3) 显示特征变量重要性

```
# 显示特征变量重要性

from xgboost import plot_importance
plt.rcParams["figure.figsize"] = (12,10)
plot_importance(XGBC_model)
plt.show()
```






图 4-18 XGBoost 模型变量重要性

4)模型的 ROC 曲线和 P-R 曲线

```
#ROC曲线和P-R曲线
#FTR: 假阳性率, TPR: 真阳性率
FPR,TPR,thresholds = roc_curve(Y_test,XGBC_model.predict_proba(X_test)[:,1],pos_label=1)
roc_auc = auc(FPR,TPR) #auc值
plt.figure(figsize=(15,6))
plt.subplot(1,2,1)
plt.plot(FPR,TPR,color = 'r',linewidth=2,label=f'ROC curve={roc_auc}')
plt.plot([0,1],[0,1],color='k',linewidth=1,linestyle='--')
plt.xlim([-0.001,1.01])
plt.ylim([-0.001,1.01])
plt.xlabel('FPR')
plt.ylabel('TPR')
plt.title('ROC_curve')
plt.legend(loc = 'best')
plt.subplot(1,2,2)
PRE,REC,thresholds = precision_recall_curve(Y_test,XGBC_model.predict_proba(X_test)[:,1],pos_label=1)
plt.plot(REC, PRE, color = 'r', linewidth = 2, label = f'accuracy\_score = \{accuracy\_score(Y\_test, XGBC\_model.predict(X\_test))\}')
plt.plot([0,1],[1,PRE.min()],color='k',linewidth=1,linestyle='--')
plt.xlim([-0.001,1.01])
plt.ylim([PRE.min()-0.001,1.01])
plt.xlabel('R')
plt.ylabel('P')
plt.title('P-R_curve')
plt.legend(loc = 'best')
plt.show()
print("AUC: ",roc_auc)
print("The total accuracy is: ",accuracy_score(Y_test,XGBC_model.predict(X_test)))
```






AUC: 0.9602459916538546 The total accuracy is: 0.9301075268817204

图 4-19 XGBoost ROC 曲线, P R 曲线

5) 模型可视化(部分),以及最终模型建立

```
#模型可视化(部分)
import xgboost
digraph1 = xgboost.to_graphviz(XGBC_model,num_trees=8)
digraph1
```



六、模型应用

1)将模型用于预测测试集

```
# 按照筛选的变量取出测试集数据
test_X = test_.loc[:,selector_X]
# 模型预测测试集
test_pred = XGBC_model.predict(test_X)
test_pred_prob = XGBC_model.predict_proba(test_X)
# 构造预测概率dataframe
test_pred_prob_df = pd.DataFrame(test_pred_prob, columns=['class_0', 'class_1'])
test_pred_prob_df
   class_0 class_1
0 0.660142 0.339858
1 0.660142 0.339858
2 0.660142 0.339858
3 0.660142 0.339858
4 0.660142 0.339858
print('预测结果: ',test_pred)
预测结果: [00000]
                           图 6-1 模型应用预测测试集
```

2) 构造提交结果

```
submission = pd.DataFrame(columns=['Id','class_0','class_1'])
submission.Id = test_.Id
submission.class_0 = test_pred_prob_df.class_0
submission.class_1 = test_pred_prob_df.class_1
submission.head()
```


	Id	class_0	class_1
0	00eed32682bb	0.660142	0.339858
1	010ebe33f668	0.660142	0.339858
2	02fa521e1838	0.660142	0.339858
3	040e15f562a2	0.660142	0.339858
4	046e85c7cc7f	0.660142	0.339858

```
submission.to_csv('/kaggle/working/submission.csv',index=False)
#submission.to_csv('submission.csv',index=False)
```

图 6-2 构造提交结果

七、数据分析结论

参与 Kaggle 进行中的竞赛结果:



公榜: 1730/2659; 排名前 66%

结论:

- 1. 采用基于 XGBClassifier 的 SelectFromModel 进行特征选择, 筛选 DU, AB, CR, BQ, FR, DA, GL, CU, DY, EB, AF, FE, EG, BG, FI, DE, EE, DI, FS, DH, BR, AZ, FD, BH, CB, BD, EH, AY, DV 共计 29 个重要变量, 这些变量对于预测受试者是否患有 B, D, G 其中一种或者多种疾病发挥着重要的作用, 其中所列出的 29 个特征的变量重要性依次递减;
- 2. 同时根据前文提出的诸多问题进行总结:
- a. 在训练集数据量有限的情况下,应当尽可能地减少暴力删除缺失值,按照赛题给定的实验数据进行有效的填补才是比较好的处理方式;
- b. 在数据集当中如果数据集的特征变量是脱敏的情况下,我们则不能简单的采取结合主题进行筛选的方式,本文通过基本模型建模以及结合网格搜索的结果进行误差、评估指标的探索,综合评估选取 XGBClassifier 转为最终模型,并且采取基于 XGBClassifier 的 SelectFromModel 特征选择方法,同时对于变量不平衡问题进行探索解决,采用集成学习的阈值调整方法。
- c. 在进行模型网格调优的时候,如果数据量并不是较大的时候,并不建议采用 10 折交叉验证,通过测试,5 折交叉验证效果更不错,避免模型过拟合;还有对于网格搜索调优的结果应该继续误差验证分析,如果只是简单采用网格搜索的最优参数可能会导致模型过拟合,在后续应用并不会有较好的表现。

附录

数据集情况(部分)

训练集:

	Id	AB	AF	AH	AM	AR	AX	AY	AZ	BC	BD	BN	BP	BQ	BR	BZ	СВ	CC	CD	Н	CL	CR	CS	CU	CW	DA	D'
1	000ff2bfdfe9	0.2093	3109	85.2	22	8.13	0.699	0.025	9.8	5.5	4126	22.5	17	152	823	25	47	0	23	П	1.0	0	13.7	1	36	6	295.
2	007255e47698	0.1452	978.7	85.2	36	8.13	3.632	0.025	13	1.2	5496	19.4	15	14.7	51	25	30	0	50	, ,	1.1	1	28.3	1	37	7	178.
3	013f2bd269f5	0.47003	2635	85.2	32	8.13	6.732	0.025	12	1.2	5135	26.4	12	219	482	25	32	0	85		1.0	0	39.3	1	21	7	321
4	043ac50845d5	0.2521	3819	120	77	8.13	3.685	0.025	11	1.2	4169	23.6	23	11.0	661	25	15	0	88		1.4	0	41.1	0	21	4	196
5	044fb8a146ec	0.3802	3733	85.2	14	8.13	3.942	0.054	3.3	102	5728	24.0	32	149	607	25	82	0	72		1.0	0	31.7	0	34	7	200.
6	04517a3c90bd	0.2093	2615	85.2	8.5	8.13	4.013	0.025	12	1.2	5237	10.2	14	16.5	642	25	18	0	80		1.0	0	32.4	1	7.0	5	135
7	049232ca8356	0.3482	1733	85.2	8.3	15.3	1.913	0.025	6.5	1.2	5710	17.6	14	344	719	25	38	0	78		1.0	0	13.7	2	21	1	107
8	057287f2da6d	0.2691	966.4	85.2	21	8.13	4.987	0.025	9.4	1.2	5040	20.8	17	6.19	701	25	12	0	71		1.0	1	41.9	1	42	6	326.
9	0594b00fb30a	0.3461	3238	85.2	28	8.13	4.021	0.025	8.2	3.6	6569	20.4	13		601	25	11	0	93		1.0	1	29.9	1	43	7	231.
10	05f2bc0155cd	0.3247	5188	85.2	12	8.13	4.593	0.025	10	1.2	4951	21.8	20	107	906	25	41	0	58		1.0	0	36.7	1	36	3	403.
11	06055f3f6785	0.5042	6089	85.2	189	17.0	6.2013	10.31	14	212	4388	25.4	19	344	51	59	47	0	132		1.0	0	17.0	2	50	6	189.
12	06554e7b9979	0.7605	6957	200	23	8.13	7.627	0.025	16	1.2	1208	26.4	39	28.9	827	25	12	0	66	П	1.0	0	44.5	0	36	5	204
13	068a4e4bbbab	0.4913	2627	138	48	8.13	4.216	0.025	12	1.2	5688	23.6	33	101	343	25	66	0	69		3.2	0	47.2	0	36	6	353
14	06c0ddf265c5	0.5341	4784	90.7	8.7	8.13	7.003	0.025	10	14	5535	24.7	37	344	670	10	19	0	126	, ,	1.2	0	33.2	1	31	3	211.
15	075bd937ab85	0.5084	1632	85.2	11	17.6	7.104	0.234	12	11	1056	26.4	33	73.2	276	13	12	0	23	П	1.0	0	70.3	1	38	5	203

名义测试集: (真正的竞赛评价采用隐藏测试集)

	Id	AB	AF	АН	AM	AR	AX	AY	AZ	ВС	BD	BN	ВР	BQ	BR	BZ	СВ	СС	CD	CF	СН	CL	CR	CS	CU	CW	DA	DE	DF	DH	DI	DL	DN	DU	DV	
1	00eed32682bb	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
2	010ebe33f668	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	02fa521e1838	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4	040e15f562a2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
5	046e85c7cc7f	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

greeks(训练集的补充元数据集):

	Id	Alpha	Beta	Gamma	Delta	Epsilon
1	000ff2bfdfe9	В	С	G	D	3/19/2019
2	007255e47698	Α	С	М	В	Unknown
3	013f2bd269f5	А	С	М	В	Unknown
4	043ac50845d5	А	С	М	В	Unknown
5	044fb8a146ec	D	В	F	В	3/25/2020
6	04517a3c90bd	А	С	М	В	10/1/2019
7	049232ca8356	А	С	М	В	5/29/2019
8	057287f2da6d	Α	C	М	В	4/24/2019
9	0594b00fb30a	А	С	М	В	2/18/2019
10	05f2bc0155cd	Α	В	М	В	6/19/2020
11	06055f3f6785	D	В	F	В	6/23/2020
12	06554e7b9979	Α	С	N	В	12/18/2019
13	068a4e4bbbab	Α	С	N	В	11/8/2019
14	06c0ddf265c5	D	В	E	В	9/27/2019
15	075bd937ab85	А	С	М	С	12/13/2018

sample_submission(提交结果的样式):

	Id	class_0	class_1
1	00eed32682bb	0.5	0.5
2	010ebe33f668	0.5	0.5
3	02fa521e1838	0.5	0.5
4	040e15f562a2	0.5	0.5
5	046e85c7cc7f	0.5	0.5